Dönem İçi Proje Raporu

Ders: AIC515 Görüntü İşleme — Prof. Dr. Onur Osman, Topkapı Üniversitesi **Öğrenci / Grup:** ……. (en fazla 3 kişi) **Tarih:** Kasım 2026 · **Sürüm:** v3 (9 Kasım 2026: simülasyon/toplu test arayüzü, Hugging Face ZeroGPU dağıtımı ve uygulama doğrulaması eklendi; önceki taslak: Vize_Raporu_Taslak.md) **Canlı uygulama:** https://huggingface.co/spaces/infinayazilim/ai515 (ZeroGPU; veri seti özel Storage Bucket'ta)

Özet — projeye beş soruda bakış

Soru	Yanıt		
Hangi veri tabanı?	**AIForge-Doc v1** (Scam.AI, Hugging Face Scam-AI/AIForge-Doc-v1, CC BY-NC-SA 4.0, e-posta kapılı): CORD v2, WildReceipt, SROIE ve XFUND kaynaklı **4.061 fiş/form görüntüsü**nde tek bir alan (fiyat, tarih, telefon, adres) **üretken yapay zekâ inpainting**'i (Gemini 2.5 Flash Image %89.6, Ideogram v2 Edit %10.4) ile değiştirilmiş; her sahte için 0/255 ikili maske ve eşleşen orijinal (authentic) görüntü var. 3.249 eğitim + 812 test. Yerel kopya 12.187 dosya, 9.98 GB.		
Amaç nedir?	(i) Bir belge görüntüsünün sahte olup olmadığını **sınıflandırmak** (ResNet-18, klasik öznitelik + SVM/RF) ve (ii) değiştirilen pikselleri **segmente etmek** (U-Net); ders konularını (yoğunluk/histogram/eşikleme/frekans/morfoloji → öznitelik → CNN → U-Net) tek bir uygulamalı hat üzerinde kullanmak.		
Neyi bulmaya çalışıyoruz?	Araştırma sorusu: *Kutu (bbox) maskesiyle eğitilen lokalizasyon modelleri gerçekte neyi öğreniyor?* Eşleşen orijinalden türetilen **piksel-değişim GT'si** ile bbox GT'si aynı tahminleri çok farklı puanlıyor mu (H1); bbox modeli dikdörtgen/sınır kısayolu mu öğreniyor (H2); piksel GT'si dayanıklılık/transfer avantajı sağlıyor mu (H3); alan dışında küresel bir iz var mı (H4)? Ek bulgu: veri setinde **yeşil işaretçi kalıntısı** adlı bir üretim artefaktı.		
Literatürde neler yapılmış?	Veri seti makalesi yalnız **zero-shot** sonuç veriyor (TruFor img-AUC 0.751, IoU 0.358, F1 0.434; DocTamper 0.563/0.020; GPT-4o 0.509). Belge sahteciliği lokalizasyonunda DTD (CVPR'23), FFDN (ECCV'24), ADCD-Net (ICCV'25) JPEG/DCT ipuçlarına dayanır; DOCFORGE-BENCH (2026) 14 yöntemin 8 sette zero-shot çöktüğünü gösterir. v1'de **eğitilmiş** model yalnız hakemsiz GitHub projelerinde (Joya15 Tiny U-Net F1 0.322); v2'de eş zamanlı hakemsiz bir eğitimli dedektör + hat-artefaktı kontrolü (Helali, Kas 2026) var.		

Sonuçlar ve benchmark'lar?	Küçük veri (400/100): ResNet-18 tam fine-tune AUROC **0.899** (probe 0.726, sıfırdan 0.679; RF 0.706, SVM 0.646); U-Net RGB Pixel-F1 **0.707**, IoU 0.637. Tam veri, resmî test (812), 3 tohum: U-Net bbox-GT **AUPRC 0.950 ± 0.011, F1@τ∗ 0.846 ± 0.015, IoU 0.789** — zero-shot TruFor F1 0.403 / ADCD-Net 0.182'nin çok üstünde (eşit koşul değil). Ancak aynı tahminler piksel-değişim GT'siyle **F1 0.45, AUPRC 0.37**'ye düşer (H1 doğrulandı); yeşil işaretçi tek başına kutuyu tetikler (authentic + işaretçi AP 0.906).		
Uygulama ve doğrulama?	Gradio arayüzü (Hugging Face Space, ZeroGPU): veri setinden bir örnek seçilip **simülasyon** olarak adım adım test edilir (GT analizi → işaretçi taraması → senaryo/bozulma → ResNet-18 + U-Net → iki GT ile metrik → görüntü-düzeyi karar → indirilebilir rapor); **toplu test** N örnekte aynı hattı koşturur. Canlı Space'te 24 sahte + 24 authentic test çiftinde bbox-GT U-Net **F1 0.925, AP 0.964**, görüntü AUROC 0.988; boru hattının kayıtlı sonuçlarıyla fark **	ΔF1	= 0.000 **(birebir yeniden üretim). Yerel otomatik test:** 281 kontrol, 0 hata**; tarayıcı (UI) testi hatasız.

1. Proje Adı

Yapay Zekâ ile Üretilmiş Finansal Belge Sahteciliğinin Tespiti ve Manipüle Edilmiş Bölgelerin Segmentasyonu: AIForge-Doc Veri Setinde Klasik Görüntü İşleme, ResNet ve U-Net Karşılaştırması

İngilizce çalışma başlığı (bildiri): *What Do Document Forgery Localizers Learn from Box Masks? Pixel-Change Ground Truth and Shortcut Audits for AI-Inpainted Financial Documents*.

2. Literatür

2.1 Problem

Üretken görüntü servisleri (Gemini 2.5 Flash Image, Ideogram v2 Edit, GPT-Image-2) bir fiş ya da formdaki tek bir alanı inpainting ile, gözle ayırt edilemeyecek biçimde değiştirebilmektedir. Problem iki düzeydedir: **görüntü-düzeyi sahtecilik tespiti** (sınıflandırma) ve **kurcalama lokalizasyonu** (ikili semantik segmentasyon; dersin 13. hafta U-Net konusu). Kurcalanan alan görüntünün medyan **%0.98**'idir; bu, küçük-ön-plan segmentasyonu problemidir ve sabit eşikli F1 ile AUPRC'nin birlikte raporlanmasını gerektirir.

2.2 Bu veri setiyle yapılmış çalışmalar

- **Wu ve ark. (2026a, arXiv:2602.20569) — veri seti makalesi.** 4.061 sahte; mevcut dedektörleri zero-shot değerlendirir: TruFor img-AUC 0.751 [0.726, 0.776], pixel-IoU 0.358, F1 0.434; DocTamper/DTD AUC 0.563, IoU 0.020; GPT-4o AUC 0.509 (Tablo 2). Makale §3.4, Gemini için bağlam kırpıntısına **3 px parlak yeşil dikdörtgen** çizildiğini; §3.3/§4.2, GT maskesinin **alanın tam bbox'ı** olduğunu belirtir. Bu iki tasarım kararı projemizin iki ana bulgusunun kaynağıdır.

- **Wu ve ark. (2026b, arXiv:2604.25213) — AIForge-Doc v2.** GPT-Image-2 ile 3.066 sahte; insan 2AFC 0.501, TruFor AUC 0.599, DocTamper 0.585; aynı dedektörler geleneksel splicing setlerinde 0.962 / 0.852 → AI-inpainting'e özgü 0.27–0.36 AUC açığı.
- **Raj ve ark. (2026, arXiv:2609.13617) — v3.** GPT-Image-2.5; lokalizasyonun zayıf kaldığını bildirir (yapıştırma-dikişi kısayolu ayrıntıları bu raporda doğrulanamadığından nitel olarak anılmaktadır).
- **Eğitilmiş modeller (hakemsiz):** Joya15 (GitHub) v1+v2+GPT4o-Receipt birleşiminde **Tiny U-Net** ile piksel F1 0.322 / IoU 0.192 ve SegFormer-lite ile çapraz-veri F1 0.044 (v2→v1); leongyiquan/DocDet karo-sınıflandırıcı ResNet-18 (sayfa AUC 0.80, lokalizasyon yok); **Helali (2026, Zenodo 10.5281/zenodo.23917285, 3 Kasım)** v2'de 371k parametreli FCN eğitmiş (img-AUC 0.989) ve "process-twin" kontrolüyle (içerik değişmeden hattan geçen orijinaller) twin'lerin %37.7'sinin sahte işaretlendiğini göstermiştir — üretim-hattı artefaktı kısayolunun bağımsız kanıtı.
- **Boşluk (savunulabilir biçimiyle):** v1 üzerinde eğitim maskesinin geometrisini kontrollü değiştiren, piksel-değişim/glif GT'si türeten ve §3.4'teki işaretçinin kalıntısını ölçen bir çalışma yoktur; v2'de görüntü-düzeyi hat-artefaktı kontrolü yapan eş zamanlı hakemsiz bir çalışma vardır. "AIForge-Doc'ta ilk denetimli eğitim" iddiası **kullanılmamaktadır**.

2.3 Belge sahteciliği lokalizasyonunda yöntemler ve benchmark'lar

Yöntem (mekân)	Ana fikir	DocTamper-Test	FCD	SCD	AIForge-Doc v1 (zero-shot)
DTD / DocTamper (CVPR 2023)	RGB + 8×8 blok DCT + JPEG kuantizasyon tablosu, Swin	F1 0.792 / IoU 0.828	0.816	0.754	F1 0.030 / IoU 0.020 / AUC 0.563
FFDN (ECCV 2024)	Sıfır-başlatılmış frekans dalı + Haar dalgacık	0.86 / 0.90 (JPEG Q75: 0.75)	0.92	0.81	—
ADCD-Net (ICCV 2025)	DCT hizalama skoruyla adaptif ağırlık; 1 px kaydırmada DTD'nin F1'i −%73	0.806	0.815	0.740 (ort. 0.787; SOTA'yı ort. %20.8 aşar)	bu proje: F1 0.182 / IoU 0.149
TruFor (CVPR 2023)	Noiseprint++ gürültü artığı + RGB	0.168 (resmî ckpt)	0.109	0.281	**F1 0.434 / IoU 0.358 / AUC 0.751** (makale); bu proje 0.403 / 0.328
CAT-Net / MVSS-Net	DCT-JPEG / gürültü + Sobel kenar	0.700 / 0.431	0.553 / 0.424	0.631 / 0.414	—
DOCFORGE-BENCH (2026)	14 yöntem × 8 set zero-shot	ort. F1: TruFor 0.34, CAT-Net 0.33, ADCD 0.23, FFDN 0.17, DTD 0.16, IML-ViT 0.08			—

Diğer ilgili çalışmalar: TGIF (WIFS 2024) ve TGIF2 (2026) — difüzyon inpainting'de görüntü tamamen yeniden üretildiğinde F1 ≤ 0.1; INP-X (2026) — inpaint dışı pikseller geri konunca ticari dedektör doğruluğu %91 → %55 (küresel hat artefaktı kısayolu); DiffusionPrint (2026); Pandolfini ve ark. (2025) — <%20 alanlı düzenlemelerde tam-görüntü dedektörlerinin çöküşü; TextShield-R1 (AAAI 2026), DocShield (2026), GenText-Forensics Challenge (ACM MM 2026). **Kısayol öğrenme** çerçevesi: Geirhos ve ark. (2020); GenD (WACV 2026) eşleşmiş gerçek–sahte eğitimin çapraz-veri AUROC'u için gerekli olduğunu; DocQT (2026) yalnız JPEG kuantizasyon tablosu farkının FFDN'yi etkilediğini raporlar. Tam matris: `literature/literature_matrix.xlsx` (38 çalışma + 2026-11 eklemeleri).

2.4 Projede kullanılan modellerin kaynakları

Model / teknik	Sunulduğu çalışma
ResNet-18	He, Zhang, Ren, Sun, CVPR 2016
U-Net	Ronneberger, Fischer, Brox, MICCAI 2015
ImageNet ön-eğitim / transfer	Deng ve ark., CVPR 2009; Yosinski ve ark., NeurIPS 2014
LBP / GLCM / 2-B DCT	Ojala ve ark., TPAMI 2002 / Haralick ve ark., TSMC 1973 / Ahmed ve ark., IEEE TC 1974

SVM / Random Forest	Cortes & Vapnik 1995 / Breiman 2001
Dice kaybı	Milletari ve ark., 3DV 2016
Frekans-domeni filtreleme, morfoloji, Otsu, Sauvola	Gonzalez & Woods, *Digital Image Processing* 3. baskı (Böl. 3–4, 9–10); Sauvola & Pietikäinen 2000

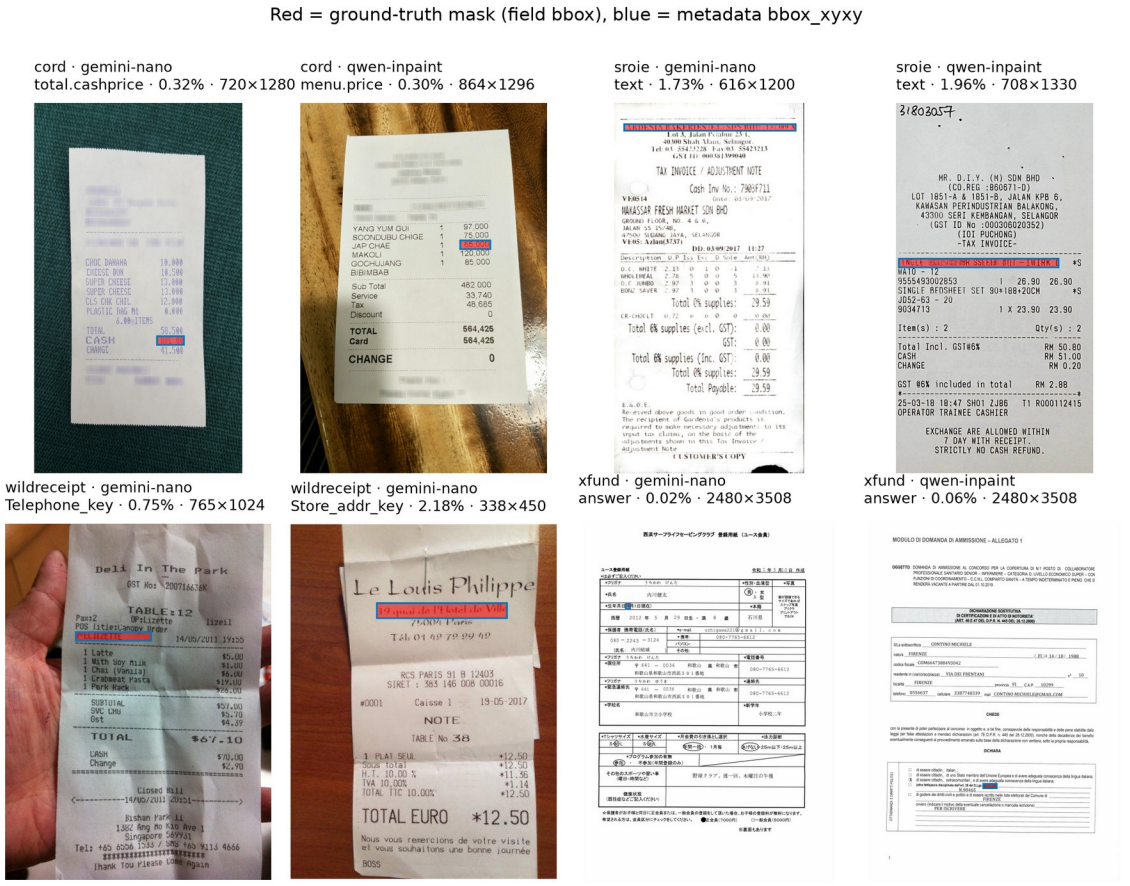
2.5 Veri seti seçiminin gerekçesi

AIForge-Doc v1 dersin örnek listesinde (Oxford Pets, ISIC 2018, Kvasir-SEG, MVTec AD…) yer almamakla birlikte aynı şablona oturur: HF kartı görevleri `image-classification` + `image-segmentation` olarak etiketler; 4.061 görüntü 0/255 ikili maskelidir; Kvasir-SEG/ISIC gibi "küçük ön plan, ikili maske" yapısına ve MVTec benzeri anomali-lokalizasyonu karakterine sahiptir; yayımlanmış zero-shot referanslar karşılaştırma tabanı sağlar; lisans akademik kullanıma açıktır (ham veri yeniden dağıtılmaz, yalnız türetilmiş maske/kod paylaşılır). Finansal belge sahteciliği, uygulama alanı olarak da güncel ve ekonomik değeri yüksek bir problemdir.

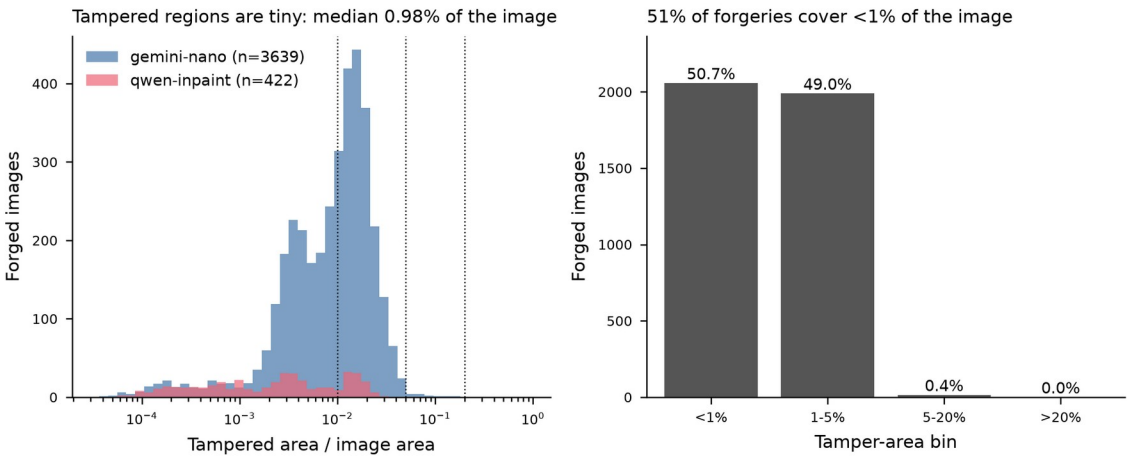
3. Materyal ve Metot

3.1 Veri tabanı: AIForge-Doc v1 (yerel audit ile doğrulandı)

- **İçerik:** 3.249 eğitim + 812 test sahte (RGB PNG) ve ikili maske; eğitim tarafında 3.247/3.249 sahtenin eşleşen authentic'i doğrulandı. Kaynak: WildReceipt 1.696, CORD 1.000, SROIE 946, XFUND 419; fiş %89.7, form %10.3; 9 dil (EN 2.642, ID 1.000); Gemini 3.639 (%89.6), Ideogram 422 (%10.4).
- **Manipülasyon:** tek alanın değeri değiştirilir; bbox %50 genişletilmiş bağlam penceresi inpaint edilir, yalnız alan bbox'ı geri yapıştırılır; GT maskesi = alan bbox'ı (tüm maskeler tek dikdörtgen).
- **İstatistikler:** çözünürlük 150×168 – 6016×7016 px (medyan 750×1296); kurcalanmış alan / görüntü alanı medyan **%0.98** (%50.7'si < %1); maske yüksekliği medyan 33 px → görüntü küçültülmeden **natif çözünürlükte crop** zorunlu (uzun kenar > 4096 px olan ~%5 görüntü çıkarımda 4096'ya küçültülür); piksel dengesizliği ≈ 1:100.
- **Audit bulguları:** (i) maskeler bbox düzeyinde; eşleşen authentic ile fark alındığında bbox piksellerinin medyan %49'u gerçekten değişir (ε=8); (ii) çiftlerin %33.5'inde bbox dışında da değişim vardır; (iii) `TestingSet/authentic` test sahtelerinin aynası değildir → image-level test metriği verilemez; (iv) test sahtelerinin %8.9'u eğitimdeki bir kaynak belgeyi paylaşır → "temiz test" alt kümesi (740) ayrıca raporlanır; (v) **sahtelerin %75.4'ünde bbox iç kenarında 1–3 px yeşil işaretçi kalıntısı** (Gemini %83.6, Ideogram %1.5; 600 authentic'te 0).
- **Bölme (test setine dokunulmadı):** kaynak-belge gruplarına göre train 2.762 / val 487 (15 kusurlu çift dışlanınca 2.748); dönem içi deneyler için smoke_train 400 / smoke_val 100 (alan dilimine tabakalı, kaynak×generator dengeli) — `dataset_audit/splits.json`.



Örnek görüntü–maske çiftleri



Kurcalanmış alan oranı dağılımı

3.2 Genel işlem hattı

1. **Natif çözünürlükte crop:** sahte görüntüden maske-bbox merkezli 256×256 (sınıflandırma) / 512×512 (segmentasyon) crop; aynı görüntüden maskeyle kesişmeyen temiz crop; eşleşen authentic'ten aynı koordinatlı temiz crop (içerik-kontrollü negatif).

2. **Klasik öznitelikler (56) + SVM-RBF / Random Forest.**
3. **ResNet-18:** (a) dondurulmuş gövde + yeni FC (linear probe), (b) tam fine-tune, (c) sıfırdan.
4. **U-Net (ResNet-18 kodlayıcı):** D1 RGB; D2 RGB + FFT yüksek-geçiren + Laplacian artığı (5 kanal). PHASE 2'de aynı mimari üç farklı GT (bbox / piksel-değişim / glif) ile 3 tohum.
5. **Değerlendirme:** sınıflandırmada Acc, Bal.Acc, AUROC, F1; segmentasyonda Pixel-F1@τ, IoU, Dice, AUPRC, AUROC, Oracle-F1; generator / kaynak / alan-dilimi kırılımı; JPEG Q75, 0.75× yeniden ölçekleme, Gauss blur dayanıklılık probları; benign kontroller; kaynak-grubu bootstrap %95 GA ve Holm düzeltmesi.

3.3 Ön işleme ve gerekçesi

Adli sinyal düşük seviyeli istatistiklerdedir (gürültü artığı, yeniden-örnekleme/sıkıştırma izi, glif kenarı). Bu yüzden görüntü *iyileştirme* amaçlı ön işleme yapılmamış; yalnız izi koruyan, sahte/authentic için simetrik adımlar uygulanmıştır: kayıpsız PNG okuma (BGR→RGB), yeniden boyutlandırma olmadan natif crop (küçük görüntülerde kenar kopyası dolgu), ImageNet ortalama/std normalizasyonu, eğitimde ±%8 parlaklık/kontrast jitter'ı, **geometrik artırım yok** (metin yönü), çıkarımda 512 px pencere / 448 px adım / örtüşme ortalaması. Klasik hatta gri dönüşüm + LBP/GLCM/DCT/Laplacian/FFT; D2'de frekans kanalları. Morfoloji ve Sauvola yalnız GT türetiminde kullanıldı. Yapılmayanların (küçültme, gürültü giderme, JPEG) etkisi test-zamanı bozulma probuyla ölçüldü (Tablo E ve §4.3).

Ders konularının tamamı (yoğunluk dönüşümü, histogram, eşikleme, gürültü giderme, keskinleştirme, kenar, morfoloji, geometrik dönüşüm, normalizasyon, frekans domeni, K-Means/watershed) bu raporla birlikte teslim edilen **aşamalı Gradio arayüzünde** (§3.8) uygulanabilir ve her adımın model çıktısına etkisi ölçülebilir.

3.4 Klasik öznitelikler (Hafta 3–4, 9–11)

8×8 blok DCT: F(u,v)=\tfrac14 C(u)C(v)\sum_{x=0}^{7}\sum_{y=0}^{7} f(x,y)\cos\!\big[\tfrac{(2x+1)u\pi}{16}\big] \cos\!\big[\tfrac{(2y+1)v\pi}{16}\big], C(0)=1/\sqrt2, C(k>0)=1; ilk 15 zigzag AC katsayısının blok-ortalama/std'si (30), DC std (1), düşük/orta/yüksek bant enerji oranları (3). **LBP** (P=8, R=1, uniform): LBP=\sum_{p} s(g_p-g_c)2^p; 10 kutulu histogram. **GLCM** (32 seviye, d=1, 4 yön ort.): kontrast, homojenlik, enerji, korelasyon. **Laplacian artığı** r=f*nabla^2 (3×3): *mean|r|, std, basıklık, çarpıklık. FFT radyal spektrum: düşük/orta/yüksek bant enerji oranları + log-spektrum eğimi. SVM-RBF: \min \tfrac12|w|^2 + C\sum\xi_i, K(x,x')=\exp(-\gamma|x-x'|^2). RF:** 500 ağaç, Gini önemi.

```
for each patch P (gri):
   f_dct <- block_dct_stats(P, 8, n_ac=15);  f_lbp <- hist(LBP(P,8,1,'uniform'),10)
   f_glcm <- mean_angles([contrast, homogeneity, energy, correlation])
   f_hp <- stats(P * Laplacian3x3);  f_fft <- radial_band_ratios(|FFT2(P)|)
   x <- concat(...)                          # 56 öznitelik
X <- StandardScaler.fit_transform(X_train); clf <- SVM_RBF | RandomForest(500)
```

3.5 ResNet-18 ile patch sınıflandırma (Hafta 12)

Residual blok y=\mathcal F(x,\{W_i\})+x; 4 aşama × 2 temel blok, GAP, FC(512→1). Kayıp: \mathcal L_{BCE}=-[y\log\hat p+(1-y)\log(1-\hat p)]; AdamW, cosine LR, 12 epoch, batch 32, bf16; giriş 256 natif patch'in 224 kesiti (yeniden örnekleme yok); yatay çevirme yok.

```
model <- resnet18(IMAGENET1K_V1); model.fc <- Linear(512,1)
if probe: freeze all but fc
for epoch: loss <- BCEWithLogits(model(x), y); step;  val_auroc -> best checkpoint
```

3.6 U-Net ile piksel segmentasyonu (Hafta 13)

Kodlayıcı ResNet-18 (ImageNet), 4 kademe kod çözücü, atlama bağlantıları d_l=\mathrm{Up}(d_{l+1})\oplus e_l; çıkış piksel logit'i. Kayıp \mathcal L=\mathcal L_{BCE}+\mathcal L_{Dice}, \mathcal L_{Dice}=1-\frac{2\sum\hat p_i y_i+\epsilon}{\sum\hat p_i+\sum y_i+\epsilon}. D2'de giriş [R,G,B,g^{FFT}_{HP},r_{Lap}]; H_{HP}(u,v)=1-e^{-D^2/(2D_0^2)}, D_0=20. Eğitim: 512 natif crop (%70 bbox içeren), AdamW 1e-4, PHASE 1: 15 epoch/batch 8; PHASE 2: 10 epoch/batch 16, 3 tohum.

```
for epoch: z <- UNet(x); loss <- BCE(z,m) + Dice(σ(z),m); step
val: F1@τ, IoU, AUPRC, Oracle-F1;  τ* <- val ızgarası (0.05..0.95) → test'e taşınır
son-işleme (Hafta 6): eşik / Otsu + morfolojik açma-kapama + en büyük bileşen bbox'ı
```

GT türetimi (PHASE 2): D=\max_c|f-a|; piksel GT = (D>8) → 3×3 açma → <8 px bileşen filtresi → 3×3 kapama; glif GT = [Sauvola(f) ∪ Sauvola(a)] ∩ dilate(D>8, 3 px), polarite azınlık sınıfı. ε-duyarlılık: bbox-dışı pikselleri > %1 değişen çift oranı ε=0'da %47.8 → ε=8'de %1.3.

3.7 Değerlendirme ölçütleri

P=\frac{TP}{TP+FP}, R=\frac{TP}{TP+FN}, F_1=\frac{2PR}{P+R}, IoU=\frac{TP}{TP+FP+FN}; AUROC/AUPRC eşikten bağımsız; Oracle-F1 görüntü başına en iyi eşik. PHASE 1 AUPRC'si crop başına ≤20k negatif alt-örneklemesiyle hesaplandığından **şişkindir** (pozitif önseli ≈%4.7 → ≈%38) ve PHASE 2'nin 256-bin histogramla kesin hesaplanan AUPRC'siyle karşılaştırılamaz; AUROC ve F1 bu etkiden bağımsızdır. İstatistik: kaynak-grubu bootstrap (B=1000) %95 GA, tohumlar sabit faktör, Holm düzeltmesi (58 ön-kayıtlı test).

3.8 Uygulama: simülasyon + aşamalı Gradio arayüzü (app/app.py)

Ders konularını ve projenin modellerini tek arayüzde, **adım adım** çalıştırmak için geliştirildi. Aynı dosya yerelde (`python app/app.py`) ve Hugging Face Space'te (https://huggingface.co/spaces/infinayazilim/ai515) çalışır. Sekmeler: **0 · Simülasyon**, **1 · Toplu test**, 2 · Girdi, 3 · Ön işleme, 4 · U-Net, 5 · ResNet-18, 6 · Yeşil işaretçi, 7 · Sonuçlar ve model kartı.

3.8.1 Simülasyon (tek örnek). Kullanıcı veri setinden bir örnek seçer: bölüm (train/test), kaynak veri seti (CORD, WildReceipt, SROIE, XFUND), inpainting üreticisi (Gemini/Ideogram), değiştirilen alan oranı (<%1, %1–5, >%5), yeşil işaretçi kalıntısı (var/yok) ve en fazla megapiksel filtreleriyle listeyi daraltır; **Rastgele seç** ya da kimlikle (`testing:000000700` gibi) seçim yapılır. Ardından *girdi senaryosu* ve *test-zamanı bozulması* seçilir:

Senaryo	Modelin gördüğü girdi	Beklenen doğru karar	Amaç
Sahte belge (forged)	veri setindeki sahte görüntü	SAHTE	standart lokalizasyon
Authentic eş (negatif kontrol)	eşleşen orijinal görüntü	GERÇEK	yanlış alarm ölçümü
Sahte, yeşil işaretçi onarılmış	sahte; işaretçi pikselleri authentic'ten kopyalanmış	SAHTE	modelin işaretçiye bağımlılığı
Authentic + yalnız yeşil işaretçi	authentic; yalnız işaretçi pikselleri sahteden aktarılmış	GERÇEK	kısayol testi (PHASE 2 Ek-C)

Bozulmalar: JPEG Q75/Q50, 0.75×/0.5× yeniden ölçekleme, Gauss bulanıklık (σ=1), Gauss gürültüsü (σ=5); istenirse Ön işleme sekmesindeki pipeline da uygulanır. Simülasyon 7 adımı canlı günlükle gösterir: (1) veri yükleme, (2) GT analizi (bbox piksellerinin ne kadarı gerçekten değişmiş, ε=8), (3) yeşil işaretçi taraması, (4) model girdisinin hazırlanması, (5) çıkarım, (6) değerlendirme, (7) rapor. Çıktılar: adım adım görüntü galerisi (sahte, bbox GT, authentic, |sahte−authentic| farkı, piksel-değişim GT, model olasılık haritaları ve ResNet patch ısı haritası), alan kutusu çevresinde **yakın plan paneli**, model başına sonuç tablosu, görüntü-düzeyi **karar ve doğru/yanlış işareti**, otomatik yorum (dikdörtgensellik, H1 farkı, işaretçi uyarısı, boru hattı kayıtlı sonucuyla fark)

ve indirilebilir MD/JSON/CSV/PNG raporu. **Bu örneği ön işleme / model sekmelerine aktar** düğmesi aynı örneği ders sekmelerine taşır.

3.8.2 Toplu test. Aynı filtrelerle N rastgele örnek (tohumlu) seçilip iki modda koşturulur: *yalnız sahte* (lokalizasyon) ya da *sahte + authentic eşi* (dengeli tespit). Model başına ortalama F1/IoU/AP (bbox-GT ve piksel-GT), tespit TPR, yanlış alarm FPR, doğruluk, görüntü AUROC ve **boru hattının kayıtlı sonuçlarıyla yeniden üretim farkı** (|ΔF1@0.5|, |ΔAP|) raporlanır; özet grafik ve CSV/JSON indirilebilir.

3.8.3 Ölçüt tanımları (boru hattıyla birebir). Olasılık haritası 8-bit'e nicemlenir (kayıtlı PNG tahminleriyle aynı); AP 256 kutulu histogramla **tüm pikseller** üzerinden kesin hesaplanır (alt-örnekleme yok); F1@τ ikili maske u8 ≥ ⌈255·τ⌉; τ değerleri `tau.json`'dan (val'de seçilmiş τ∗), Oracle-F1 görüntü başına en iyi eşik. Görüntü-düzeyi skor = olasılık haritasının en yüksek %1 piksel ortalaması; karar eşiği val bölümündeki 487 sahte + 487 eşleşen authentic üzerinde Youden-J ile seçildi (`meta/image_tau.json`): bbox-GT s42 τ=0.167 (val TPR 0.879, FPR 0.150, AUROC 0.921), piksel-GT s42 τ=0.084 (0.862 / 0.209 / 0.885), glif-GT s42 τ=0.067 (0.823 / 0.314 / 0.796); ResNet-18 için görüntü skoru = en yüksek patch skoru, eşik 0.5. Çıkarım `infer_fullimage.py` protokolüyle aynıdır: 512 px pencere, 448 adım, örtüşme ortalaması; >4096 px kenarlar önce küçültülür.

3.8.4 Dağıtım mimarisi. Space, Gradio 6 ve **ZeroGPU** (dinamik GPU; NVIDIA RTX Pro 6000 Blackwell, ücretsiz kota) üzerinde çalışır: `spaces` paketi torch'tan önce yüklenir, modeller açılışta GPU'ya taşınır, çıkarım `@spaces.GPU` ile işaretli fonksiyonda (süre örnek boyutuna göre dinamik) yapılır; yerelde dekoratör etkisizdir. Veri seti lisansı (CC BY-NC-SA 4.0, kapılı) nedeniyle ham veri Space reposuna konmadı: 12.208 dosya (10.26 GiB; görüntüler, maskeler, modeller, audit tabloları) **özel** bir Hugging Face Storage Bucket'a (`infinayazilim/ai515-data`) yüklendi ve Space'e salt-okunur `/data` olarak bağlandı (`AI515_DATA_ROOT`). Space reposunda yalnız kod, sonuç tabloları ve küçük meta dosyaları vardır. Dağıtım betiği: `hf_space/deploy_hf.py`; canlı test: `hf_space/live_test.py`.

AIC515 Görüntü İşleme · AIForge-Doc — Belge Sahteciliği Tespiti ve Lokalizasyonu

Simülasyon sekmesinde veri setinden bir fiş/form seçin; uygulama ground-truth analizini, yeşil işaretçi taramasını, seçtiğiniz girdi senaryosunu ve bozulmayı uygulayıp ResNet-18 ve U-Net modellerini adım adım çalıştırır, sonuçları iki farklı GT ile ölçer ve görüntü-düzeyi karar verir. **Toplu test** aynı hattı N örnekte koşturur. Diğer sekmeler ders konularını (61 ön işleme işlemi) aşamalı olarak uygulamaya yarar.

Veri seti: 4061 sahte görüntü dizinde · model: 8 yüklü · cihaz: `cpu` · veri kökü `/home/claude/t2`

0 · Simülasyon | 1 · Toplu test | 2 · Girdi | 3 · Ön işleme (aşamalı pipeline) | 4 · U-Net lokalizasyonu | 5 · ResNet-18 patch sınıflandırma | 6 · Yeşil işaretçi sondası | 7 · Sonuçlar ve model kartı

1) Örnek seçimi

Bölüm: test (testing) | Kaynak veri seti: hepsi

Inpainting üreticisi: hepsi | Kurcalanan alan oranı: hepsi

Yeşil işaretçi kalıntısı: hepsi | En fazla megapiksel: 12 (0.1 – 40)

☑ Yalnız authentic eşi olanlar (piksel-GT ve işaretçi senaryoları için gerekli)

Filtrele | Rastgele seç

88 örnek filtreye uyuyor · rastgele seçildi: `testing:000000700`

Örnek (bölüm:kimlik) — listeden seçin ya da yazın: testing:000000700 · wildreceipt · Gemini · alan <1% · 1.9 MP · eşli · işaretçi

2) Senaryo

Girdi senaryosu:
- (●) Sahte belge (forged)
- ( ) Authentic eş (negatif kontrol)
- ( ) Sahte, yeşil işaretçi onarılmış
- ( ) Authentic + yalnız yeşil işaretçi (kısayol testi)

Test-zamanı bozulma: Yok (ham PNG)

☐ Ön işleme sekmesindeki pipeline'ı da uygula

3) Modeller

U-Net (piksel lokalizasyonu):
- ☑ U-Net · bbox-GT (s42)
- ☑ U-Net · glif-GT (s42)
- ☑ U-Net · piksel-GT (s42)
- ☐ U-Net · RGB (PHASE1, 400 örnek)
- ☐ U-Net · RGB+FFT+Laplacian (PHASE1)

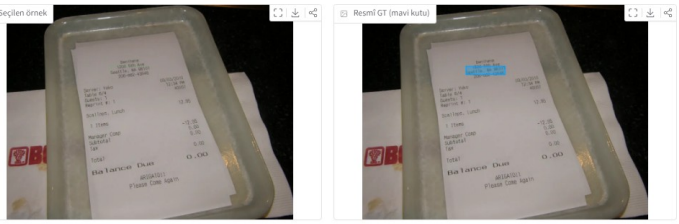
ResNet-18 (patch sınıflandırma):
- ☑ ResNet-18 · tam ince ayar
- ☐ ResNet-18 · linear probe
- ☐ ResNet-18 · sıfırdan

ResNet kayan pencere adımı (px): 112 (56 – 224)

▶ Simülasyonu başlat

Bu örneği ön işleme / model sekmelerine aktar

Seçilen örnek | Resmî GT (mavi kutu)



testing:000000700 · wildreceipt · Gemini · receipt · dil `en` · 1600×1200 px (1.92 MP)
Değiştirilen alan `Store_addr_key: Seattle,WA98101 → Seattle,WA43846` · alan dilimi <1%
GT (bbox) maskesi: 10340 px (%0.54)
Authentic eş: `wildreceipt_00999.png` ✓

Simülasyon · `testing:000000700`

- ✓ **1/7 Veri yüklendi — 1600×1200 px, GT var, authentic var** · 0.0 s
- ✓ **2/7 Ground truth analizi — bbox piksellerinin %17'i gerçekten değişmiş (ε=8); bbox dışında 0 değişen piksel** · 0.3 s
- ✓ **3/7 Yeşil işaretçi taraması — kutu kenarında 264 px → kalıntı VAR** · 0.4 s
- ✓ **4/7 Model girdisi hazır — sahte belge olduğu gibi; gerçek etiket SAHTE** · 0.4 s
- ✓ **5/7 Çıkarım tamamlandı — 25.8 s (cpu)** · 26.2 s
- ✓ **6/7 Değerlendirme — metrikler hesaplandı** · 26.6 s
- ✓ **7/7 Rapor hazır — toplam 27.1 s** · 27.1 s

Gerçek etiket: SAHTE — sahte belge olduğu gibi

- ✅ **ResNet-18 · tam ince ayar → SAHTE** (skor 1.000 ≥ eşik 0.500)
- ✅ **U-Net · bbox-GT (s42) → SAHTE** (skor 0.662 ≥ eşik 0.167)
- ✅ **U-Net · piksel-GT (s42) → SAHTE** (skor 0.202 ≥ eşik 0.084)
- ✅ **U-Net · glif-GT (s42) → SAHTE** (skor 0.415 ≥ eşik 0.067)

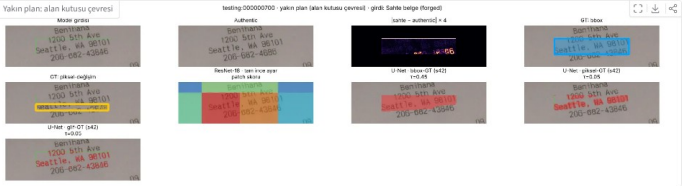
Yorum

- **Kutu davranışı:** bbox-GT modelinin tahmini dikdörtgensellik 0.06 — tahmin glif düzeyinde parçalı.
- **H1 (GT seçimi):** aynı tahmin bbox-GT ile F1 0.783, piksel-değişim GT ile F1 0.015 → fark +0.768. Kutu maskesi, değişmeyen kutu piksellerini de doğru sayar; raporlanan skor GT tanımına bağlıdır.
- **GT analizi:** bbox piksellerinin %17'i gerçekten değişmiş (ε=8); bbox dışında 0 değişen piksel.
- **Yeşil işaretçi:** kutu kenarında 264 px kalıntı var. 'Sahte, yeşil işaretçi onarılmış' senaryosuyla tekrar çalıştırıp skorun ne kadar düştüğüne bakın (PHASE 2 Ek-C: AP 0,988 → 0,763).
- **Yeniden üretim:** boru hattının kayıtlı F1 (τ = 0,5) = 0.860, uygulamanın hesapladığı = 0.846 (fark -0.014).

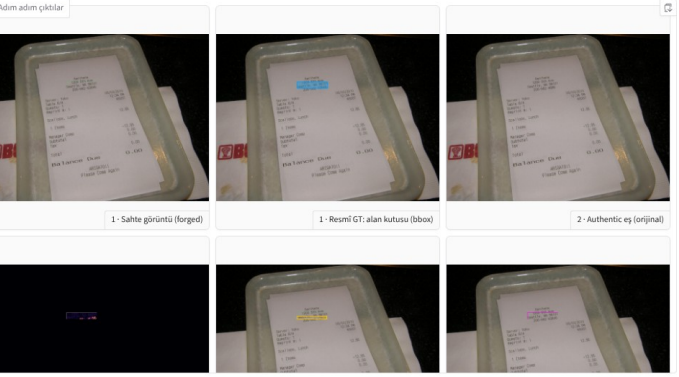
Model bazında sonuçlar

Model	Görüntü skoru	Görüntü eşiği	Karar	Doğru	τ piksel	F1 bbox-GT	IoU bbox-GT	AP bbox-GT	Oracle-F1	F1 piksel-GT	pi
ResNet-18 · tam ince ayar	1	0.500	SAHTE	√	–	–	–	–	–	–	–
U-Net · bbox-GT (s42)	0.662	0.167	SAHTE	√	0.45	0.783	0.643	0.902	0.913	0.015	0.0
U-Net · piksel-GT (s42)	0.202	0.084	SAHTE	√	0.05	0.482	0.318	0.423	0.484	0.004	0.0
U-Net · glif-GT (s42)	0.415	0.067	SAHTE	√	0.05	0.188	0.104	0.091	0.202	0.04	0.0

Yakın plan: alan kutusu çevresi



Adım adım çıktılar



Simülasyon raporu (MD · JSON · CSV · PNG)

testing_000000700_rapor.md — 3.2 KB ↓

Simülasyon sekmesi — testing:000000700 (WildReceipt, Gemini, alan <%1): 7 adım, karar, metrikler, yakın plan ve rapor dosyaları

AIC515 Görüntü İşleme · AIForge-Doc — Belge Sahteciliği Tespiti ve Lokalizasyonu

Simülasyon sekmesinde veri setinden bir fiş/form seçin; uygulama ground-truth analizini, yeşil işaretçi taramasını, seçtiğiniz girdi senaryosunu ve bozulmayı uygulayıp ResNet-18 ve U-Net modellerini adım adım çalıştırır, sonuçları iki farklı GT ile ölçer ve görüntü-düzeyi karar verir. **Toplu test** aynı hattı N örnekte koşturur. Diğer sekmeler ders konularını (61 ön işleme işlemi) aşamalı olarak uygulamaya yarar.

Veri seti: 4061 sahte görüntü dizinde · model: 8 yüklü · cihaz: `cpu` · veri kökü `/home/claude/t2`

0 · Simülasyon | 1 · Toplu test | 2 · Girdi | 3 · Ön işleme (aşamalı pipeline) | 4 · U-Net lokalizasyonu | 5 · ResNet-18 patch sınıflandırma | 6 · Yeşil işaretçi sondası | 7 · Sonuçlar ve model kartı

1) Örnek seçimi

Bölüm: test (testing) | Kaynak veri seti: hepsi

Inpainting üreticisi: hepsi | Kurcalanan alan oranı: hepsi

Yeşil işaretçi kalıntısı: hepsi | En fazla megapiksel: 12 (0.1 – 40)

☑ Yalnız authentic eşi olanlar (piksel-GT ve işaretçi senaryoları için gerekli)

Filtrele | Rastgele seç

88 örnek filtreye uyuyor · rastgele seçildi: `testing:000000700`

Örnek (bölüm:kimlik) — listeden seçin ya da yazın

testing:000000700 · wildreceipt · Gemini · alan <1% · 1.9 MP · eşli · işaretçi

2) Senaryo

Girdi senaryosu

- ○ Sahte belge (forged)
- ○ Authentic eş (negatif kontrol)
- ○ Sahte, yeşil işaretçi onarılmış
- ◉ Authentic + yalnız yeşil işaretçi (kısayol testi)

Test-zamanı bozulma: Yok (ham PNG)

☐ Ön işleme sekmesindeki pipeline'ı da uygula

3) Modeller

U-Net (piksel lokalizasyonu)

- ☑ U-Net · bbox-GT (s42)
- ☑ U-Net · glif-GT (s42)
- ☑ U-Net · piksel-GT (s42)
- ☐ U-Net · RGB (PHASE1, 400 örnek)
- ☐ U-Net · RGB+FFT+Laplacian (PHASE1)

ResNet-18 (patch sınıflandırma)

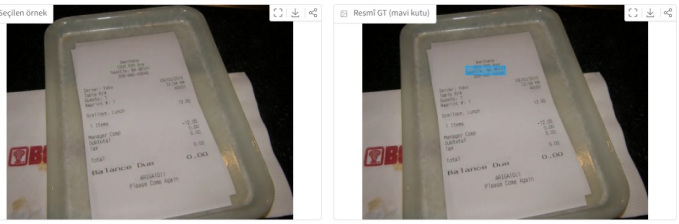
- ☑ ResNet-18 · tam ince ayar
- ☐ ResNet-18 · linear probe
- ☐ ResNet-18 · sıfırdan

ResNet kayan pencere adımı (px): 112 (56 – 224)

▶ Simülasyonu başlat

Bu örneği ön işleme / model sekmelerine aktar

Seçilen örnek | Resmî GT (mavi kutu)



testing:000000700 · wildreceipt · Gemini · receipt · dil `en` · 1600×1200 px (1.92 MP)
Değiştirilen alan `Store_addr_key: Seattle,WA98101 → Seattle,WA43846` · alan dilimi <1%
GT (bbox) maskesi: 10340 px (%0.54)
Authentic eş: `wildreceipt_00999.png` ✓

Simülasyon · `testing:000000700`

- ✓ **1/7 Veri yüklendi — 1600×1200 px, GT var, authentic var** · 0.0 s
- ✓ **2/7 Ground truth analizi — bbox piksellerinin %17'i gerçekten değişmiş (ε=8); bbox dışında 0 değişen piksel** · 0.3 s
- ✓ **3/7 Yeşil işaretçi taraması — kutu kenarında 264 px → kalıntı VAR** · 0.3 s
- ✓ **4/7 Model girdisi hazır — orijinal belge + yalnız 798 px yeşil işaretçi (hiçbir karakter değişmedi); gerçek etiket GERÇEK** · 0.4 s
- ✓ **5/7 Çıkarım tamamlandı — 25.7 s (cpu)** · 26.2 s
- ✓ **6/7 Değerlendirme — metrikler hesaplandı** · 26.4 s
- ✓ **7/7 Rapor hazır — toplam 26.8 s** · 26.8 s

Gerçek etiket: GERÇEK — orijinal belge + yalnız 798 px yeşil işaretçi (hiçbir karakter değişmedi)

- ❌ **ResNet-18 · tam ince ayar → SAHTE** (skor 1.000 ≥ eşik 0.500)
- ❌ **U-Net · bbox-GT (s42) → SAHTE** (skor 0.648 ≥ eşik 0.167)
- ❌ **U-Net · piksel-GT (s42) → SAHTE** (skor 0.197 ≥ eşik 0.084)
- ❌ **U-Net · glif-GT (s42) → SAHTE** (skor 0.404 ≥ eşik 0.067)

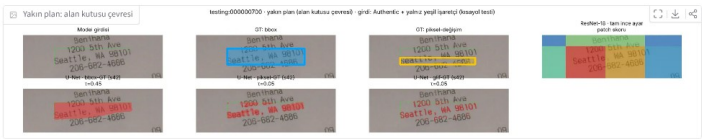
Yorum

- **Kutu davranışı:** bbox-GT modelinin tahmini dikdörtgensellik 0.06 — tahmin glif düzeyinde parçalı.
- **GT analizi:** bbox piksellerinin %17'i gerçekten değişmiş (ε=8); bbox dışında 0 değişen piksel.
- **Yeşil işaretçi:** kutu kenarında 264 px kalıntı var. 'Sahte, yeşil işaretçi onarılmış' senaryosuyla tekrar çalıştırıp skorun ne kadar düştüğüne bakın (PHASE 2 Ek-C: AP 0,988 → 0,763).
- **Kısayol testi:** içerik değişmediği hâlde bbox-GT modeli kutunun %83'ini işaretledi → model içeriği değil işaretçiyi kullanıyor.

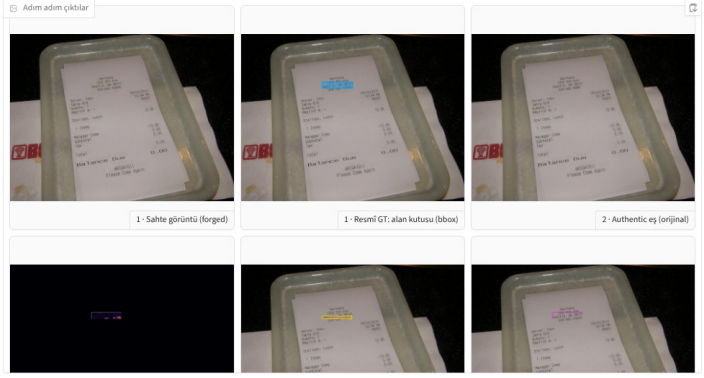
Model bazında sonuçlar

Model	Görüntü skoru	Görüntü eşiği	Karar	Doğru	τ piksel	F1 bbox-GT	IoU bbox-GT	AP bbox-GT	Oracle-F1	F1 piksel-GT	AP piksel-GT	Kutu kapsama	Pozitif piksel %
ResNet-18 · tam ince ayar	1	0.500	SAHTE	×	–	–	–	–	–	–	–	–	–
U-Net · bbox-GT (s42)	0.648	0.167	SAHTE	×	0.45	–	–	–	–	–	–	0.826	0.624
U-Net · piksel-GT (s42)	0.197	0.084	SAHTE	×	0.05	–	–	–	–	–	–	0.364	0.296
U-Net · glif-GT (s42)	0.404	0.067	SAHTE	×	0.05	–	–	–	–	–	–	0.205	0.79

Yakın plan: alan kutusu çevresi



Adım adım çıktılar



1 · Sahte görüntü (forged) | 1 · Resmî GT: alan kutusu (bbox) | 2 · Authentic eş (orijinal)

Simülasyon raporu (MD · JSON · CSV · PNG)

testing_000000700_rapor.md — 3.1 KB ↓

Simülasyon — "Authentic + yalnız yeşil işaretçi" kısayol testi: değiştirilmemiş belgede modeller kutuyu çizip SAHTE der



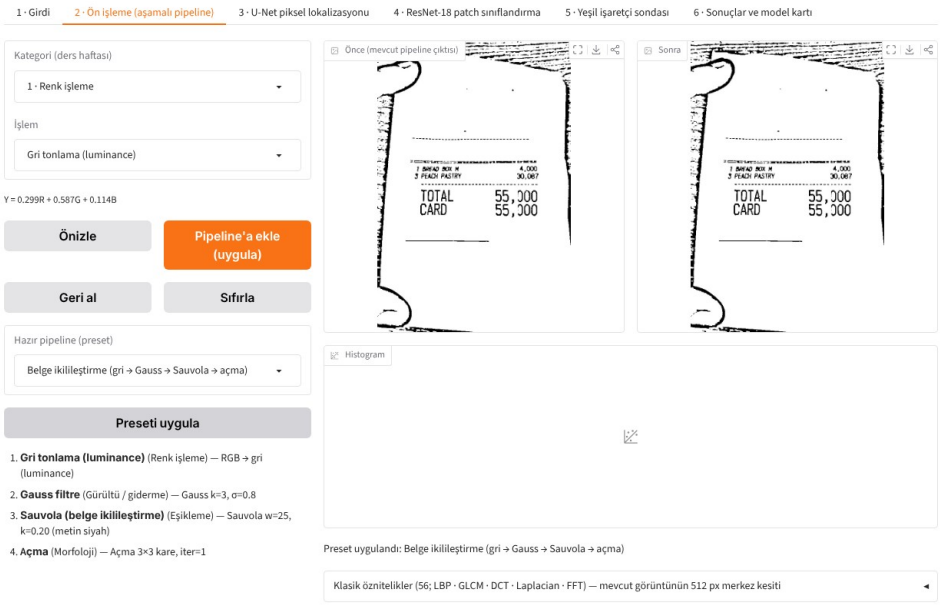
Toplu test sekmesi — dengeli tespit modu, model bazında özet, grafik ve örnek bazında sonuçlar

3.8.5 Ders sekmeleri (2–7).

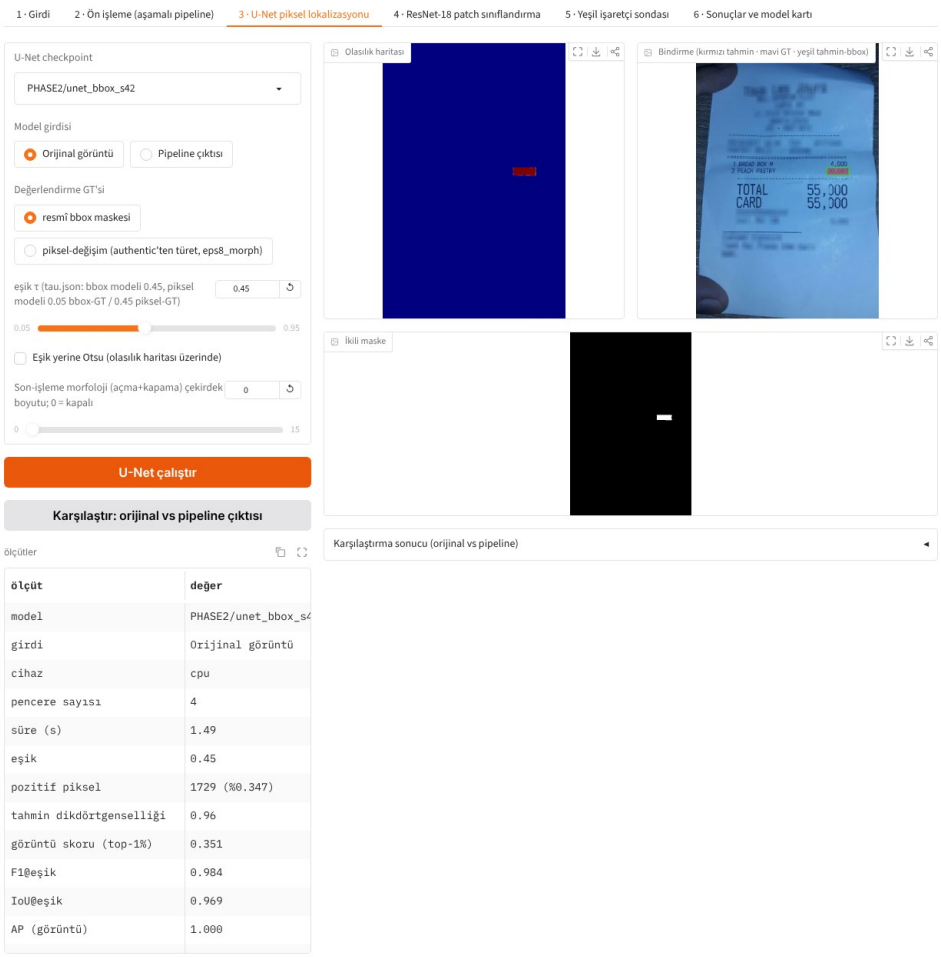
- **Girdi:** sahte görüntü + isteğe bağlı GT maskesi + authentic eş yükleme ya da veri setinden örnek seçme (metadata ve authentic eş otomatik).
- **Ön işleme (13 kategori / 61 işlem):** renk işleme; yoğunluk dönüşümleri (negatif, log, gamma, kontrast germe, dilimleme, bit düzlemi); histogram (eşitleme, CLAHE); eşikleme (global, Otsu, adaptif, Sauvola); gürültü ekleme/giderme (box, medyan, Gauss, bilateral, NLM); keskinleştirme (Laplacian, unsharp/high-

boost); kenar (Sobel, Prewitt, Scharr, Laplacian, LoG, Canny); morfoloji (erozyon, genişleme, açma, kapama, gradyan, top/black-hat, bileşen filtresi); geometrik (döndürme, ölçekleme, öteleme, aynalama, shear, kırpma); normalizasyon (min-max, z-score, ImageNet, boyut); frekans domeni (FFT spektrumu, ideal/Gauss/Butterworth LP-HP, projenin D2 kanalları, blok DCT); klasik segmentasyon (K-Means, watershed, bağlı bileşen); dayanıklılık bozulmaları (JPEG, yeniden ölçekleme, blur, işaretçi onarımı). Her adım **Önizle → Pipeline'a ekle → Geri al** ile yönetilir, önce/sonra görüntüsü ve histogramı gösterilir; hazır presetler ve 56 klasik öznitelik tablosu vardır.

- **Derin öğrenme:** U-Net (PHASE 1 ve PHASE 2 tüm checkpoint'leri; `infer_fullimage.py` ile aynı kayan-pencere protokolü; eşik `tau.json`'dan) ve ResNet-18 (224 natif kayan pencere); model **orijinal** ya da **pipeline çıktısı** üzerinde çalıştırılıp ölçütler yan yana karşılaştırılır; GT olarak bbox maskesi ya da authentic'ten türetilen piksel-değişim maskesi seçilebilir (H1 canlı gösterim); yeşil işaretçi sondası.



Arayüz — aşamalı ön işleme (belge ikileştirme preseti)



Arayüz — U-Net lokalizasyonu (örnek 000000329, bbox modeli; F1 0.984 bbox-GT)

3.9 Donanım ve yazılım

RTX 5080 (16 GB, CUDA 12.8), Python 3.11, PyTorch 2.11 (cu128), torchvision 0.26, segmentation-models-pytorch 0.5, scikit-learn 1.9, scikit-image, OpenCV, Gradio. Kurulum: baselines/ENV_SETUP.md; uçtan uca yeniden üretim: run_everything.ps1 (~6 saat); arayüz: app/README_APP.md. Canlı uygulama: Hugging Face Space (Python 3.12, PyTorch 2.11, Gradio 6, ZeroGPU), veri ve modeller özel Storage Bucket'tan.

4. Sonuçlar

4.1 Çok kısıtlı veri (smoke_train 400 / smoke_val 100, tek tohum) — sistemin çalıştığının gösterimi

Patch kümesi 1.587 eğitim / 296 val (tampered / clean-same / clean-paired); toplam GPU eğitim süresi 23.5 dk; test setine dokunulmadı. Değerler provizyoneldir.

B) Klasik öznitelikler + ML

Model	Acc	Bal.Acc	AUROC	AUPRC	F1@0.5	AUROC tamp-vs-paired	AUROC tamp-vs-same
SVM-RBF	0.534	0.606	0.646	0.443	0.546	0.552	0.744

(C=0.5, γ=0.01)							
Random Forest (500 ağaç)	0.622	0.653	0.706	0.536	0.573	0.610	0.807

C) ResNet-18

Ayar	best ep	Acc	Bal.Acc	AUROC	AUPRC	F1@0.5	AUROC tamp-vs-paired	TN/FP/FN/TP
Linear probe (dondurulmuş gövde + yeni FC)	10/12	0.639	0.693	0.726	0.554	0.616	0.635	103/93/14/86
Tam fine-tune (pretrained)	6/11	**0.885**	**0.845**	**0.899**	**0.884**	**0.809**	**0.878**	190/6/28/72
Sıfırdan	4/9	0.503	0.610	0.679	0.497	0.561	0.573	55/141/6/94

D) U-Net (512 natif crop; val: görüntü başına 1 bbox + 1 rastgele crop)

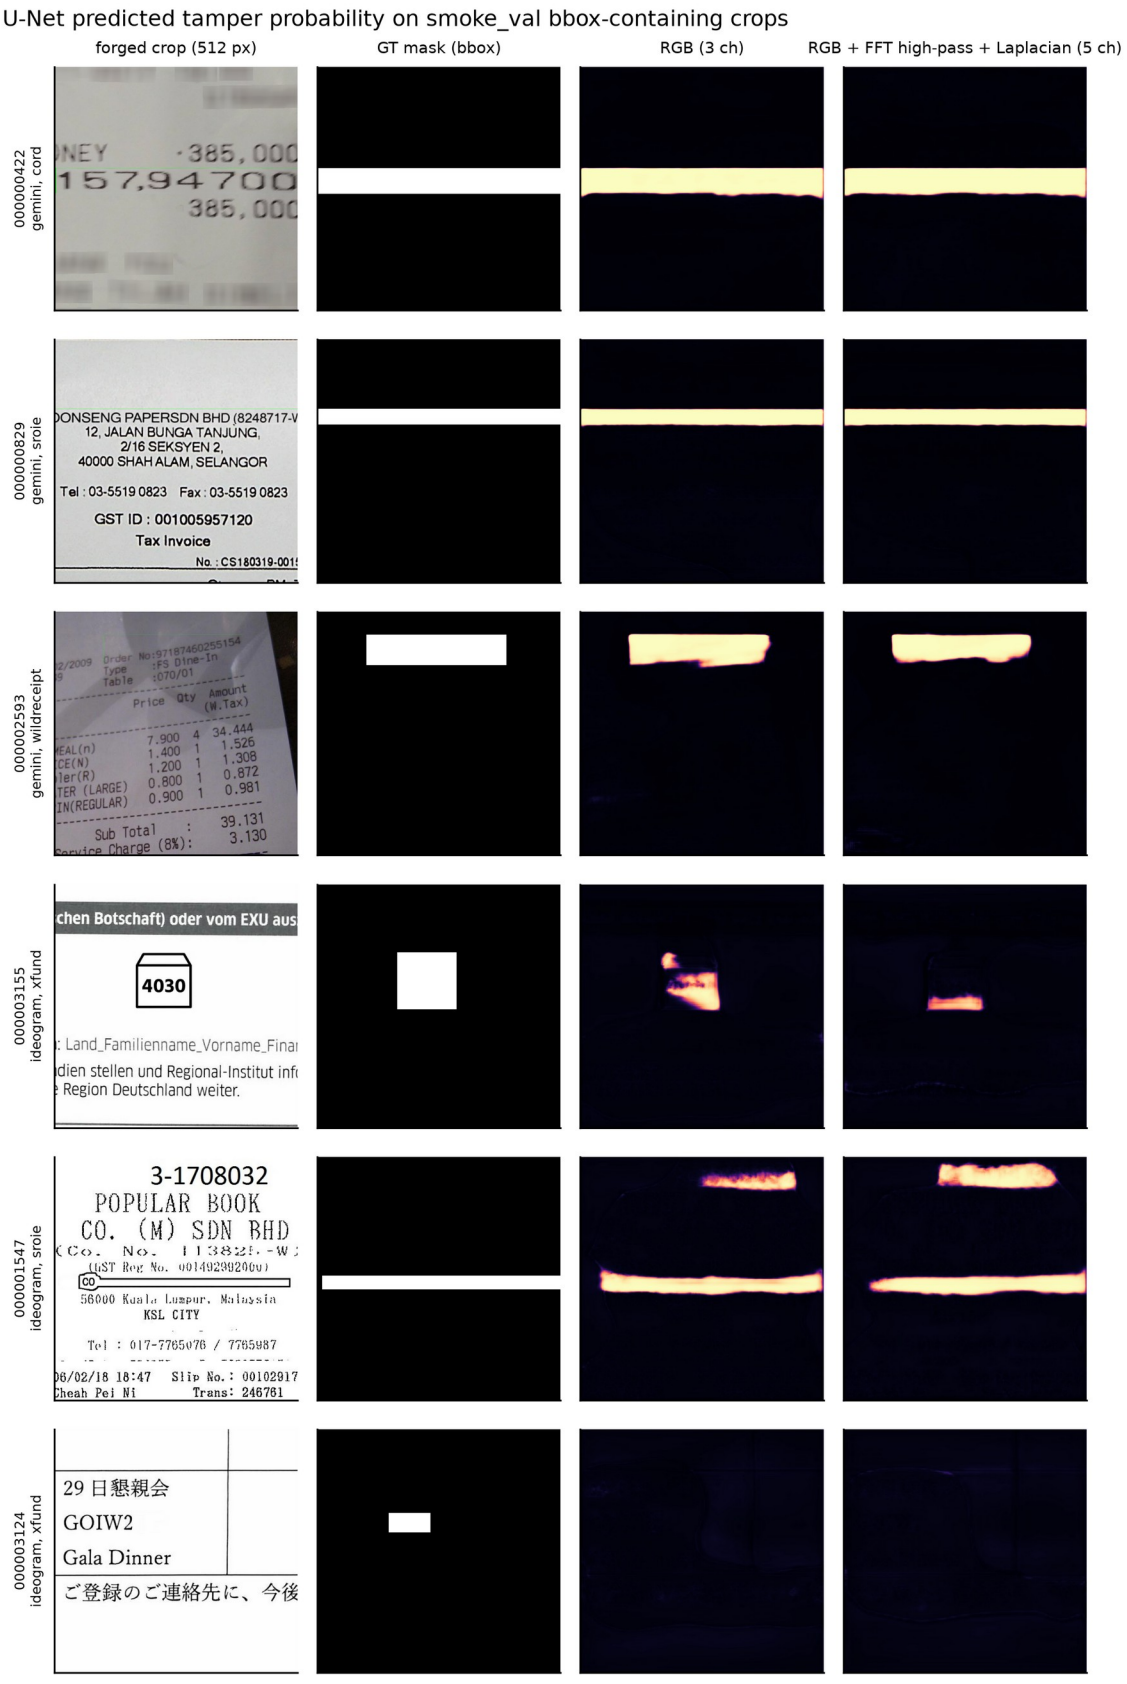
Varyant	best ep	Pixel-F1@0.5	IoU@0.5	Oracle-F1	Pixel-AUPRC∗	Pixel-AUROC	Temiz crop FP	F1 gemini / ideogram	F1 <1% / 1–5%
U-Net RGB (D1)	11/15	**0.707**	**0.637**	0.740	0.947	0.948	0.26 %	0.800 / 0.497	0.606 / 0.830
U-Net RGB+FFT-HP+Laplacian (D2)	12/15	0.674	0.613	0.711	0.939	0.940	0.14 %	0.779 / 0.449	0.589 / 0.792

∗ alt-örneklenmiş AUPRC (bkz. §3.7); PHASE 2 ile karşılaştırılamaz.

E) Dayanıklılık (eğitim yapılmadan, aynı val crop'ları)

Varyant	Koşul	Pixel-F1@0.5	IoU	Oracle-F1	Temiz crop FP
U-Net RGB	temiz PNG	0.707	0.637	0.740	0.26 %
U-Net RGB	JPEG Q75	0.636	0.565	0.680	0.18 %
U-Net RGB	0.75× → 1×	0.638	0.560	0.676	1.24 %
U-Net D2	JPEG Q75 / 0.75×	0.604 / 0.633	0.540 / 0.566	0.640 / 0.674	0.13 % / 0.42 %

F) Kaynak: ResNet-18 eğitimi 64–76 s (peak 0.33–0.59 GiB, 11.18 M parametre, çıkarım 7–8 ms/patch); U-Net ~10 dk (peak 1.7 GiB, 14.33 M, 16–19 ms/512-crop); SVM/RF 6–7 s CPU.



U-Net tahminleri: forged crop / GT (bbox) / RGB / RGB+frekans

Okuma. (1) Ön-eğitilmiş + yeni katman vs sıfırdan: tam fine-tune (0.899) ≫ probe (0.726) ≫ sıfırdan (0.679) — pretrained model yalnız gövde de güncellendiğinde kazandırıyor. (2) İçerik-kontrollü negatif (aynı koordinatlı authentic) her modelde daha zor → modeller kısmen içerik/konum ipucu kullanıyor. (3) Klasik öznitelikler şans üstü ama zayıf; veri PNG olduğundan DCT öznitelikleri ayırt edici değil (beklenen negatif bulgu). (4) U-Net RGB küçük veriyle güçlü; tahminler **bbox dikdörtgenini bütünüyle** işaretliyor → PHASE 2'nin motivasyonu. (5) Frekans kanalı eklemek RGB'yi geçmedi. (6) JPEG/yeniden ölçekleme F1'i ~7 puan düşürüyor, çöküş yok.

4.2 Tam veri (train 2.748 / val 487 / resmî test 812; 3 tohum)

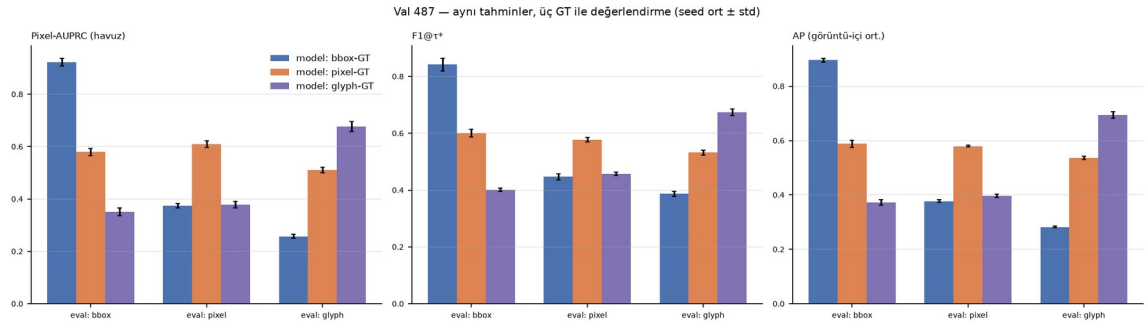
Model	Alt küme	AUPRC	F1@τ*	IoU@τ*	Oracle-F1
U-Net bbox-GT (3 tohum)	tam 812	**0.950 ± 0.011**	**0.846 ± 0.015**	**0.789 ± 0.018**	0.879 ± 0.011
U-Net bbox-GT	temiz 740	0.949 ± 0.012	0.845 ± 0.015	0.788 ± 0.018	0.878 ± 0.012
U-Net piksel-GT	tam 812	0.638 ± 0.015	0.616 ± 0.013	0.480 ± 0.015	0.624 ± 0.015
U-Net glif-GT	tam 812	0.403 ± 0.011	0.405 ± 0.007	0.266 ± 0.006	0.410 ± 0.008
TruFor zero-shot (≤2 MP)	tam 812	havuz 0.080	F1@0.5 0.403	0.328	0.456
ADCD-Net zero-shot (Q100)	tam 812	havuz 0.130	F1@0.5 0.182	0.149	0.328

Sızıntı etkisi yok (tam vs temiz ΔAP 0.001). TruFor değerleri makaledekine (0.434 / 0.358) yakın (−0.03). Zero-shot satırları eşit koşul değildir; referans olarak verilmiştir.

H1 — aynı tahminler, üç GT (val 487, AUPRC, tohum ort.):

Eğitim GT \ Değerlendirme GT	bbox	piksel	glif
bbox	**0.923 ± 0.015**	0.374 ± 0.008	0.257 ± 0.007
piksel (eps8_morph)	0.579 ± 0.014	**0.610 ± 0.012**	0.511 ± 0.010
glif (glyph_v2)	0.351 ± 0.015	0.379 ± 0.012	**0.676 ± 0.019**

Her GT kendi modelini birinci sıraya koyar; bbox modelinin ΔF1 (bbox − piksel GT) = **0.398 [0.377, 0.418]** ≫ 0.05 yanlışlama sınırı; Kendall τ (bbox vs piksel sıralaması) −0.22. **H1 doğrulandı.** Tohumlar arası std: val-crop AUPRC ≤ 0.002, tam-görüntü AUPRC 0.015, F1 0.03.



Aynı tahminler, üç GT

H2 — bbox modeli ne öğreniyor? (kısmen). Tahmin dikdörtgenselliği (3-tohum havuz medyanı): bbox 0.87 · piksel 0.32 · glif 0.05; bbox modeli alan içindeki gliflerin bulanıklaştırılmasına duyarsız (iç-blur +1.2 % AUPRC), sınır-halka blur'u yalnız −1.5 % (plasebo 0) → ön-kayıtlı **sınır-dikişi kısayolu yanlışlandı**; 0.5 eşiğinde authentic görüntülerin %44'ünde > %0.1 pozitif piksel (piksel modeli %10) ama kalibre τ*'da FP oranları benzer (kalibrasyon farkı). Image-level AUROC (top-1 %, val, 3 tohum): bbox 0.892 [0.876, 0.907], piksel 0.892, glif 0.799.

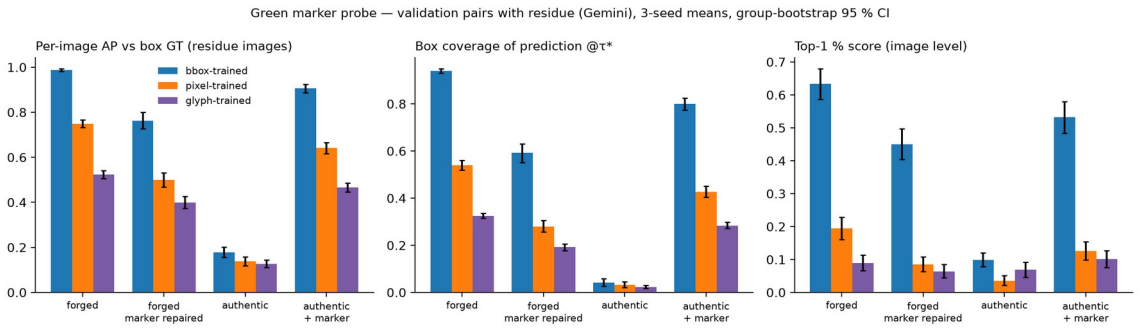
H3 — dayanıklılık / transfer (yanlışlandı). ΔAUPRC (kendi GT'si): JPEG Q75 bbox −0.154 / piksel −0.137; 0.75× −0.112 / −0.245; blur σ=1 −0.190 / −0.361. Held-out generator (Gemini-only eğitim → Ideogram): piksel − bbox ΔAP +0.025 [−0.039, 0.088] (Holm p 0.86; n=41, tek tohum → zayıf kanıt).

H4 — bbox dışında küresel iz (yanlışlandı). Maskeye değmeyen 224 crop'larda forged-vs-authentic AUROC **0.516** [0.513, 0.519] (pozitif kontrol 0.980); 260/457 çiftte bbox-dışı crop'lar piksel-özdeş.

4.3 Yeşil işaretçi kalıntısı (keşifsel sonda, 368 val çifti, 9 model)

Model	Girdi	AP (bbox GT)	Kutu kapsama @τ*	Görüntü skoru
bbox	sahte	0.988	0.940	0.634
bbox	sahte, **işaretçi onarılmış**	0.763 (Δ −0.225 [−0.262, −0.189])	0.592	0.450
bbox	authentic	0.178	0.042	0.098
bbox	**authentic + işaretçi**	**0.906 [0.887, 0.924]**	0.799	0.532
piksel	sahte / onarılmış / authentic + işaretçi	0.749 / 0.499 / 0.641	0.539 / 0.280 / 0.426	0.195 / 0.085 / 0.126
glif	sahte / onarılmış / authentic + işaretçi	0.524 / 0.400 / 0.465	0.325 / 0.193 / 0.284	0.089 / 0.064 / 0.102

Yalnız işaretçi pikselleri authentic'e aktarılınca bbox modeli kutuyu çizer; gerçek sahtede yalnız işaretçi onarılınca performansın dörtte biri gider; öğrenmesiz "yeşil çizgi → kutu" kuralı F1 0.054 verir (ipucu öğrenilmiş bir kısayoldur). Gemini–Ideogram "üretici farkı" büyük ölçüde işaretçi farkıdır. Ara yüzdeki örnek 000000329'da 74 px kalıntı tespit edilmiş, onarım adımı 240 px'i authentic'ten kopyalamıştır.



Yeşil işaretçi sondası

4.4 Arayüzle doğrulanan örnek (training:000000329, CORD, Gemini, alan < %1)

Model	GT	Eşik	F1	IoU	AP	Dikdörtgensellik
U-Net bbox-GT (s42)	bbox	0.45	**0.984**	0.969	1.000	0.96
U-Net bbox-GT (s42)	piksel-değişim	0.95	**0.635**	0.466	0.799	0.97
U-Net piksel-GT (s42)	bbox	0.05	0.808	0.679	0.764	0.11
U-Net glif-GT (s42)	bbox	0.05	0.518	0.349	0.485	0.03
U-Net RGB (PHASE 1, smoke)	bbox	0.50	0.375	0.231	0.979	0.38
U-Net bbox-GT (s42), **JPEG Q75 girdi**	bbox	0.45	0.953	0.909	0.996	0.90
ResNet-18 ft	—	—	GT'yle kesişen patch 0.65 / 0.98 (ort/maks); temiz patch 0.11 / 0.50			

Tek görüntüde bile H1 örüntüsü (aynı tahmin: bbox-GT F1 0.98 → piksel-GT 0.64) ve JPEG'in etkisi (0.98 → 0.95) yeniden üretilmektedir.

4.5 Uygulamanın doğrulanması (yerel otomatik test + canlı ZeroGPU)

Arayüzün raporlanan sonuçları değiştirmeden yeniden ürettiğini göstermek için üç düzeyde test yapıldı.

(a) Yerel otomatik test — 281 kontrol, 0 hata (tests/test_app.py, CPU). Kapsam: 61 ön işleme işleminin her biri (çıktı tipi, boyut, sonlu değer), presetler ve geri al/sıfırla; örnek filtreleri ve rastgele seçim; dört senaryo ve altı bozulma; simülasyon çıktılarının tamamı (galeri, tablo, karar, yakın plan, 4 rapor dosyası); hatalı girdiler (geçersiz kimlik, boş seçim, geometrik pipeline sonrası boyut uyuşmazlığı); toplu testin iki modu. **Yeniden üretim:** kayıtlı sonucu bulunan 33 test görüntüsünde uygulamanın hesapladığı F1@0.5 ile boru hattının kayıtlı per_image sonuçları arasındaki ortalama mutlak fark bbox-GT 0.006, piksel-GT 0.007, glif-GT 0.001 (CPU'da bf16/float yuvarlama farkı; en büyük tekil fark 0.145, küçük alanlı bir görüntüde).

(b) Tarayıcı (UI) testi (tests/ui_test.py, Playwright): örnek seçimi → simülasyon → kısayol senaryosu → ön işleme preseti → toplu test akışı gerçek bir tarayıcıda tıklanarak çalıştırıldı; hata yok (simülasyon 30 s, 6+6 örnek toplu test 51 s, CPU). Bu bölümdeki ekran görüntüleri bu testten alınmıştır.

(c) Canlı Space testi (hf_space/live_test.py, ZeroGPU, 9 Kasım 2026): gradio_client ile Space'in API'si üzerinden.

Simülasyon — rastgele seçilen `testing:000000452` (işaretçili, eşli), dört senaryo:

Senaryo	ResNet-18 ft	U-Net bbox-GT	U-Net piksel-GT	U-Net glif-GT
Sahte belge	SAHTE ✓ (0.997)	SAHTE ✓ (1.000) · F1 bbox 0.971 · F1 piksel 0.483	SAHTE ✓ (0.980) · 0.768 / 0.604	SAHTE ✓ (0.987) · 0.600 / 0.468
Authentic eş	GERÇEK ✓ (0.263)	GERÇEK ✓ (0.001)	GERÇEK ✓ (0.002)	GERÇEK ✓ (0.001)
Sahte, işaretçi onarılmış	GERÇEK ✗ (0.248)	GERÇEK ✗ (0.001) · F1 0	GERÇEK ✗ (0.002) · F1 0	GERÇEK ✗ (0.001) · F1 0
Authentic + yalnız işaretçi	SAHTE ✗ (0.997)	SAHTE ✗ (1.000) · kutu kapsama 0.907	SAHTE ✗ (0.980) · 0.610	SAHTE ✗ (0.985) · 0.442

Parantez içi: görüntü-düzeyi skor. Bu örnek, PHASE 2 Ek-C'deki kısayolun **tek görüntüde, dört modelin hepsinde** görülebildiği en net durumdur: sahte metin yerinde kalıp yalnız işaretçi silindiğinde modeller sahteciliği kaçırır; hiçbir karakter değişmeden yalnız işaretçi eklendiğinde ise kutuyu çizip SAHTE der. Modellerin bu örnekte öğrendiği şey inpainting izi değil işaretçidir. (Her senaryo çağrısı ~36 s; GPU tahsisi ve 4 modelin tam çözünürlükte çalışması dâhil.)

Toplu test — test bölümü, 24 rastgele eşli örnek (tohum 42), dengeli tespit (24 sahte + 24 authentic), 49 s:

Model	F1 bbox-GT	IoU bbox-GT	AP bbox-GT	F1 piksel-GT	AP piksel-GT	TPR	FPR	Doğruluk	Görüntü AUROC	Yeniden üretim | ΔF1@0.5|
ResNet-18 tam ince ayar	—	—	—	—	—	1.000	0.375	0.812	0.990	—
U-Net bbox-GT (s42)	**0.925**	0.871	**0.964**	0.528	0.410	1.000	0.042	0.979	0.988	**0.000** (n=24)
U-Net piksel-GT (s42)	0.739	0.602	0.730	**0.635**	**0.609**	1.000	0.083	0.958	1.000	**0.000** (n=24)

GPU'da uygulamanın hesapladığı F1 ve AP, aynı görüntülerde boru hattının kayıtlı sonuçlarıyla **birebir aynıdır** (|ΔF1| = |ΔAP| = 0.000). Örneklem küçük olduğu için mutlak değerler resmî test sonuçlarından (§4.2: F1 0.846, AUPRC 0.950) sapabilir; H1 örüntüsü (bbox-GT modeli bbox GT'siyle 0.925, aynı tahminler piksel GT'siyle 0.528) burada da korunur. ResNet-18'in yanlış alarm oranı (0.375) sabit 0.5 eşiğinden kaynaklanır; AUROC 0.990 olduğundan sıralama iyidir, eşik kalibrasyonu sonraki adımdır.

4.6 Sınırlamalar ve sonraki adımlar

- Uygulamadaki görüntü-düzeyi eşikler val'de tek tohumla (s42) seçildi; test bölümünde yalnız 89 eşli authentic olduğu için test FPR'si geniş güven aralıklıdır. ResNet-18 için eşik kalibre edilmedi (0.5).
- Smoke sonuçları tek tohum ve alt-örneklenmiş AUPRC ile provizyoneldir; tam-veri sonuçları 3 tohumludur ama tek mimariye (U-Net/ResNet-18) dayanır.
- GT doğrulaması insan yerine görsel dil modeli ile yapılmıştır (96 çift: piksel GT OK 69 / PARTIAL 26 / WRONG 1); insan denetimi beklemektedir.
- Held-out generator deneyi zayıf (Ideogram n=41, tek tohum). Image-level test metriği veri seti yapısı nedeniyle verilemez.
- Yeşil işaretçi bulgusu keşifseldir; **işaretçisiz eğitim seti ile yeniden eğitim** (3 GT × tohum), ikinci mimari, 20 epoch, AIForge-Doc v2 ve insan GT denetimi sonraki aşamadır. Bildiri hedefi: IEEE SIU 2027 / ICDAR 2027 WS / WIFS 2027.

5. Kaynaklar

Tam BibTeX: literature/references.bib (39 kayıt + bu sürümde eklenenler). Başlıcaları:

6. Wu J., Zhou Y., Xu M., et al. (2026). AIForge-Doc: A Benchmark for Detecting AI-Forged Tampering in Financial and Form Documents. arXiv:2602.20569.
7. Wu J., Zhou Y., Ng D.T., et al. (2026). When the Forger Is the Judge: GPT-Image-2 Cannot Recognize Its Own Faked Documents. arXiv:2604.25213.
8. Raj A., Zhang Y., Zewde K., et al. (2026). ChatGPT Images 2.5 on Forgery Tasks. arXiv:2609.13617.
9. Helali B. (2026). Beyond Zero-Shot on AIForge-Doc v2: A Trained Detector and a Process-Twin Control. Zenodo, doi:10.5281/zenodo.23917285 (hakemsiz).
10. Zhao Z., Xia W., Wei E., et al. (2026). DOCFORGE-BENCH. arXiv:2603.01433.
11. Qu C., Liu C., Liu Y., et al. (2023). Towards Robust Tampered Text Detection in Document Image. CVPR 2023. doi:10.1109/CVPR52729.2023.00575
12. Chen Z., et al. (2024). Enhancing Tampered Text Detection through Frequency Feature Fusion and Decomposition. ECCV 2024. doi:10.1007/978-3-031-73414-4_12
13. Wong K., et al. (2025). ADCD-Net. ICCV 2025. doi:10.1109/ICCV51701.2025.01792
14. Guillaro F., Cozzolino D., et al. (2023). TruFor. CVPR 2023. doi:10.1109/CVPR52729.2023.01974
15. Mareen H., et al. (2024). TGIF: Text-Guided Inpainting Forgery Dataset. IEEE WIFS 2024. doi:10.1109/WIFS61860.2024.10810690
16. Yermakov A., Cech J., Matas J., Fritz M. (2026). Deepfake Detection that Generalizes Across Benchmarks. WACV 2026. doi:10.1109/WACV61042.2026.00082
17. Geirhos R., et al. (2020). Shortcut Learning in Deep Neural Networks. Nature Machine Intelligence. doi:10.1038/s42256-020-00257-z
18. Nebioglu et al. (2026). INP-X. arXiv:2602.00192. · Mareen et al. (2026). TGIF2. arXiv:2603.28613. · Giakoumoglou et al. (2026). DiffusionPrint. arXiv:2604.12443.

19. He K., Zhang X., Ren S., Sun J. (2016). Deep Residual Learning for Image Recognition. CVPR 2016.
20. Ronneberger O., Fischer P., Brox T. (2015). U-Net. MICCAI 2015.
21. Ojala T., Pietikäinen M., Mäenpää T. (2002). LBP. IEEE TPAMI. · Haralick R.M., et al. (1973). Textural Features. IEEE TSMC. · Ahmed N., Natarajan T., Rao K.R. (1974). Discrete Cosine Transform. IEEE Trans. Computers.
22. Cortes C., Vapnik V. (1995). Support-Vector Networks. Machine Learning. · Breiman L. (2001). Random Forests. Machine Learning. · Milletari F., et al. (2016). V-Net / Dice loss. 3DV 2016.
23. Gonzalez R.C., Woods R.E. Digital Image Processing, 3. baskı, Pearson. · Sauvola J., Pietikäinen M. (2000). Adaptive document image binarization. Pattern Recognition.
24. Joya15 (erişim 9 Kasım 2026). Multi-Generator Deepfake Document Detection and Tamper Localization [GitHub, hakemsiz]. · leongyiquan/DocDet [GitHub, hakemsiz].